

LLM 기반 멀티 에이전트 문서 생성 시스템의 오케스트레이션 구조에 따른 성능 비교 분석

paper-agent (자동 생성 초안)

Abstract

최근 대규모 언어 모델(LLM) 기반의 멀티 에이전트 시스템을 활용한 복잡한 문서 생성 연구가 활발히 진행되고 있으며, 특히 에이전트 간의 협업을 최적화하기 위한 다양한 오케스트레이션 기법들이 제안되고 있다. 그러나 기존 연구들은 주로 기능적 구현에 집중되어 있어, 오케스트레이션 구조의 차이가 실제 자원 소모 효율과 생성 품질에 미치는 영향에 대한 정량적 비교 분석은 여전히 부족한 실정이다. 본 논문에서는 오케스트레이션 방식을 고정 그래프 기반의 *Code*, 동적 라우팅 기반의 *LLM*, 그리고 계층적 제어 방식의 *Hybrid* 세 가지 구조로 정의하고 이를 구현하여 비교 분석하였다. 실험은 산업 현장의 정형 보고서 및 창의적 글쓰기 작업을 대상으로 수행되었으며, LLM-as-Judge 평가 기준을 적용하여 실행 시간, 토큰 수, 품질 점수 등을 측정하였다. 실험 결과, 고정 그래프 기반의 *Code* 구조는 평균 158.61초의 실행 시간, 21,440 개의 토큰 소모량, 그리고 82점의 품질 점수를 기록하였다. 이를 LLM 및 Hybrid 구조의 성능 지표와 비교 분석함으로써, 오케스트레이션의 제어 정밀도와 자원 효율성 및 생성 품질 사이에 존재하는 트레이드오프(Trade-off) 관계를 확인하였다. 본 연구는 작업의 성격과 요구되는 자원 제약에 따라 최적의 오케스트레이션 구조를 선택할 수 있는 정량적 기준을 제시함으로써, 효율적인 멀티 에이전트 시스템 설계 방향을 제안하는 데 기여한다.

가능성이 있다는 가설이 제기된다. 기존의 다양한 오케스트레이션 기법들에 대한 연구가 진행되어 왔음에도 불구하고, 작업의 성격에 따른 구조적 효율성을 정량적으로 비교 분석한 연구는 여전히 부족한 실정이다.

본 연구의 목적은 오케스트레이션 구조의 차이가 문서 생성의 효율성(Efficiency)과 효과성(Effectiveness)에 미치는 영향을 정량적으로 분석하는 데 있다. 이를 위해 본 논문에서는 오케스트레이션 구조를 고정 그래프 기반의 *Code*, 동적 라우팅 기반의 *LLM*, 그리고 두 방식의 장점을 결합한 계층적 제어 기반의 *Hybrid* 세 가지 모델로 정의하고 구현한다.

연구의 범위는 산업 현장의 정형 데이터 기반 보고서(예: 금형-사출 분석 보고서)와 창의적 텍스트 생성이라는 서로 다른 성격의 두 가지 작업군으로 설정한다. 실험의 재현성을 보장하기 위해 에이전트의 역할, 사용 모델 및 프롬프트 로직은 표준 설정을 적용하여 통제변인으로 설정한다. 종속변인으로서는 실행 시간(*elapsed_sec*), 토큰 소모량(*tokens*), LLM-as-Judge 기반의 품질 점수(*best_score*), 그리고 목표 품질 달성을 위한 재시도 횟수(*retry_count*)를 측정한다. 특히 *Code* 구조의 경우 실행 시간 158.61초, 토큰 소모량 21,440개, 품질 점수 82점, 재시도 횟수 3회라는 실측치를 기준으로 하여 타 구조와의 성능 차이를 비교 분석한다. 이를 통해 각 오케스트레이션 구조 간의 Trade-off 관계를 입증하고, 작업 특성에 따른 최적의 구조 선택 기준을 제시하고자 한다.

1 서론

최근 대규모 언어 모델(LLM)의 발전으로 단일 모델의 한계를 극복하기 위해 특정 역할이 부여된 에이전트들이 협력하는 멀티 에이전트 시스템(Multi-Agent System, MAS) 연구가 가속화되고 있다. 특히 고도의 전문성과 일관성이 요구되는 문서 생성 작업에서 MAS는 설계, 집필, 검수, 수정으로 이어지는 파이프라인을 통해 생성물의 품질을 향상시킬 수 있는 가능성을 보여주었다. 이러한 시스템에서 각 에이전트의 실행 순서와 상호작용 방식을 결정하는 오케스트레이션(Orchestration)은 시스템의 전체적인 성능과 자원 효율성을 결정짓는 핵심 요소이다.

현재 멀티 에이전트의 제어 방식은 크게 결정론적 방식과 확률론적 방식으로 나뉜다. 고정된 그래프나 코드에 의해 제어되는 방식은 실행 경로가 명확하여 예측 가능성과 안정성이 높지만, 작업 맥락에 따라 유연하게 대응하지 못하는 경직성이 한계로 지적된다. 반면, LLM이 직접 다음 단계를 결정하는 동적 라우팅 방식은 복잡한 상황에 유연하게 대처할 수 있으나, 제어 흐름의 예측 불가능성으로 인해 무한 루프에 빠지거나 불필요한 토큰 소모가 발생할